

Data Science en Banques et Assurances

Mario DEFRANCE - Aurélien PACARD



Introduction



Agenda

Séance 1 Mario DEFRANCE

- Contexte économique des banques et assurances
- La data, catalyseur de transformation
- Le travail du Data Scientist
- Présentation des modèles de machine learning « classiques »
- Pratique : calcul du Taux de Rentabilité Interne d'un projet financier

Séance 2 Aurélien PACARD

- Présentation des projets Kaggle
- Démarrage des travaux, première soumission

Séance 3 Mario DEFRANCE

- Présentation du rendu attendu
- Poursuite des projets

Séance 4 Aurélien PACARD & Mario DEFRANCE

- Soutenance des projets (15 min présentation + 10 min questions)



Contexte économique et défis



En banque



Marges sur les intérêts des crédits et commissions ; frais de gestion (banque de détail)



Opérations financières, activités sur les marchés financiers, conseil et M&A (banque d'investissement)



En assurance




Plus-values entre prime et sinistres ; frais de gestion



Investissement des primes sur des fonds sécurisés (obligations, immobilier,..) ; Investissements sur des marchés financiers (assurance vie)

L'inflation impacte le résultat des Banques et Assurances




- Risque de défauts accru
- Augmentation des montants assurés et des emprunts

Fin de la pandémie Covid19 : Reprise forte de la consommation

Guerre en Ukraine : augmentation coûts énergie et alimentation

Une augmentation des taux pour contenir l'inflation ?



2010-2021 - période de taux directeurs faibles

- Marges bancaires faibles
- Épargne moins intéressante
- Plus d'emprunts = plus de demande

2022-2025 - période de taux directeurs élevés

- Marges bancaires plus importantes
- Épargne plus intéressante
- Moins d'emprunts = moins de demande

Leaders | Lessons from a bank collapse

What really went wrong at Silicon Valley Bank

America must plan better for the failure of banks that are large but not enormous

Share



Source : The Economist, 13 mars 2023

Comment Société Générale s'est fait piéger par la hausse des taux 📉

La banque a vu sa marge nette d'intérêt plonger de 27 % au troisième trimestre. En cause, notamment, une politique de couverture de taux prise à contre-courant du phénomène de remontée brutale observé depuis plus d'un an.

Offrir l'article

Ajouter à mes articles

Commenter

Partager

BNP Paribas

Société Générale




Source : Les Échos, 3 novembre 2023

EN CHIFFRES

Assurance-vie : les dépôts battent un nouveau record en novembre

Les cotisations en assurance-vie ont atteint un record en novembre 2025, à 15,7 milliards d'euros, en hausse de 4 % sur un an. La collecte nette s'approche également de son plus haut historique.

 Offrir l'article  Ajouter à mes articles  Commenter  Partager  Finances Publiques  Epargne



Source : Les Échos, 8 janvier 2026

Banque

La banque de détail redevient le moteur de croissance des banques françaises

L'évolution des taux a été très favorable au secteur bancaire hexagonal ce trimestre. La conjugaison de revenus en hausse et de frais généraux contenus sur tous les fronts leur permet d'annoncer des performances très solides et, parfois, de revoir leurs objectifs à la hausse.

Publié le 6 août 2025 à 21:29 - Maj 6 août 2025 à 22:13

Séverine Charon



Source : L'AGEFI, 6 août 2025



En Banque : Bâle 2, Bâle 3, Bâle 4

- La banque doit immobiliser une certaine somme (**fonds propres**), dépendant du montant et de la qualité des crédits qu'ils ont accordés à leurs clients, et de leurs investissements sur les marchés financiers.
- Bâle 3 : nouveaux ratios de solvabilité, notamment liquidity coverage ratio.

En Assurance: Solvabilité 2

- L'assurance doit immobiliser une somme permettant de couvrir un sinistre majeur, avec une probabilité de 99.5 %
- Cette somme dépend du montant des primes d'assurance vendues.
- L'assurance doit immobiliser des fonds supplémentaires en fonction de l'exposition de ses actifs sur les marchés financiers.





En Banque

- Loi de Modernisation de l'Économie de 2008 : mobilité bancaire gratuite
- Loi Macron de 2015 : démarche de mobilité bancaire automatisée
- Plafonnement des frais bancaires (à partir de 2028)
- Concurrence forte des néo-banques (Boursorama, REVOLUT, BforBank...) : plus de comptes ouverts que dans les banques traditionnelles
- Projet Euro Numérique (novembre 2025; BCE)

En Assurance


- Loi Lagarde de 2010 : facilite la résiliation de l'assurance emprunteur
- Loi Hamon de 2014 : facilite la résiliation des contrats d'assurance auto et habitation

Banques vs Assurances vs Bancassurances ?





La Data, au cœur de la transformation



- À très court terme : **forts enjeux de compétitivité, de pilotage de performance, d'optimisation**
- IA encore peu utilisée sur les activités à fortes valeurs ajoutées et « Core Business » : relation client, gestion financière (liquidité, taux, risques)
 - **Explicabilité des algorithmes et fiabilité des sources de données**
 - **RGPD : partage et utilisation des données sensibles**
 - Ne pas oublier les **coûts de maintenance IT**
- Stratégie adoptée : combiner expertise humaine et digitale



Données « structurées »

- Données descriptives : identité, situation familiales, âge, CSP, adresse, profession, religion ?...
- Données financières : revenus, épargne, patrimoine, crédits, Banque De France
- Données comportementales : historique de dépenses, de sinistres, accéléromètres de voiture, navigation web...

Données « non-structurées »

- Texte : garantie des contrats, documents d'informations clés, échanges de mails avec les clients, documentations...
- Audio : enregistrement des conversations entre gestionnaires et clients, réunions...
- Image : chèques, factures, pièces d'identité, cartes grises, DPE...



Les missions du Data Scientist

Les rôles et étapes d'un projet Data

Expression de besoin métier	Cadrage	Architecture	Conception de la solution	Mise en production	Monitoring
Le métier exprime son besoin au travers d'une fiche d'étude d'opportunité	La fiche d'opportunité est réceptionnée par un Chef de projet IT, qui prend en charge l'étude de cadrage	Les Data Architects sont sollicités pour le choix de la solution. Le chef de projet IT et les data architects décident d'orienter l'instruction de la solution au travers d'un produit Data/IA.	Le Chef de projet Data/IA est responsable du cadrage de la solution. Il définit les objectifs du projet et les moyens technologiques à utiliser et les contraintes à respecter (sécurité, budget). Les Data Scientists / Analysts sont mobilisés pour élaborer une solution respectant les critères définis par le CP Data.	La solution est intégrée dans le SI et déployée en production par les Data Engineers.	La solution est documentée et inscrite au sein du référentiel de produits Data par le Data Manager. Une gouvernance est mise en place pour assurer le monitoring et l'évolution de la solution.



Votre mission, si vous l'acceptez





Recette pour un bon modèle statistique



Machine Learning, Deep Learning : **comprendre** et **apprendre** un comportement à partir d'exemples.



Cible du modèle *ce que le modèle doit comprendre*

Régression *valeurs de $-\infty$ à $+\infty$ ou de 0 à 1 ou de 0 à $+\infty$...*

EXAMPLE

- Moyenne générale entre 0 et 20
- Montant de sinistre



Classification *valeurs 0 ou 1 ou 2 ou 3...*

EXAMPLE

- Obtention (1) ou non (0) du diplôme
- Opération de carte frauduleuse (1) ou non (0)



Cas 1 : Je veux construire un modèle pour estimer la probabilité de sinistre d'un assuré.
S'agit-il d'un problème de régression ou bien de classification ?



Cas 2 : Je veux construire un modèle permettant de lire un IBAN sur un Relevé d'Identité Bancaire.
S'agit-il d'un problème de régression ou bien de classification ?



Recette pour un bon modèle statistique



Type d'apprentissage *selon l'usage du modèle*

Supervisé *expliquer et/ou prédire, cible définie*

EXAMPLE

- Prédire l'obtention du diplôme
- Sinistralité d'un contrat d'assurance



Non-supervisé *définir une typologie, pas de cible*

EXAMPLE

- Déterminer des groupes d'étudiants
- Topic Modeling



Sélection du modèle *définition du problème d'optimisation*

Forme du modèle *selon la forme des données*

- La cible est une fonction des données (sa forme)
- Modèles linéaires, modèles non-paramétriques...



Fonction de perte (objectif) *distance entre la cible et le modèle*

- Quantifie la différence entre la cible et le modèle
- Objectif : valeur à optimiser (généralement minimiser)



Cas : Je veux construire un modèle de détection de la fraude à la carte bancaire, seulement 0,1% des opérations sont frauduleuses. Apprentissage supervisé ou non-supervisé ? Quelle forme de modèle sélectionner ?



Recette pour un bon modèle statistique



Les données (variables aléatoires) *ce qui définit la cible*

Quantitatives (continues) *valeurs de $-\infty$ à $+\infty$...*

EXEMPLE

- Tx. de présence en cours, nb. de soirées/semaines...
- Montants, ancienneté du client, chiffre d'affaires...



Qualitatives (discrètes, catégorielles) *valeurs 0 ou 1 ou 2...*

EXEMPLE

- A trouvé un stage/alternance, a sauté/redoublé une année...
- Cotation Banque de France, tranche d'effectifs de l'entreprise...



- **Demander aux équipes métiers** ceux qu'elles utilisent pour réaliser la tâche cible (données pertinentes)
- Feature Engineering : construire un ensemble de variables à partir des variables initiales (ratios, déviations par rapport à la moyenne par groupes...)
- Processing des données : gestion des valeurs manquantes et aberrantes (outliers), normalisation des données, encodages, découpage des variables...



Sélection des variables du modèle

Approche exhaustive

- Tester l'ensemble des combinaisons possibles
- Variables optimales pour modéliser la cible



Approche intelligente

- Stepwise, Recursive Feature Elimination, Boruta...
- Approche rapide



Une **pré-sélection** des variables selon leur association avec la cible permet de réduire drastiquement le temps nécessaire pour la sélection

Mesures d'associations	Qualitative	Quantitative
Qualitative	Cramer's V, Tschuprow's T	Kruskal-Wallis
Quantitative	Kruskal-Wallis	Pearson, Spearman



Recette pour un bon modèle statistique



(Hyper)Paramètres du modèle *ce que le modèle apprend*

Paramètres *ce qui est appris*

EXAMPLE

- Régression : coefficients de régression...
- NN : matrice de poids associées à chaque neurone...



Hyperparamètres *ce qui guide l'apprentissage*

EXAMPLE

- Régression : nombre de variables, régularisation...
- NN : nombre de couches/neurones, learning rate...



Un compromis *100€ maintenant ou 100€ l'an prochain ?*

Biais (erreur) *trop serait de l'underfitting*

EXAMPLE

- Utiliser le prénom et le nom pour prédire votre note
- Cible imprécise, pas assez de paramètres




Variance (robustesse) *trop serait de l'overfitting*

EXAMPLE

- Échantillon d'apprentissage trop petit
- Trop de variables, trop de paramètres, trop d'epoch

LARGE LANGUAGE MODEL	Parameters
Phi-1.5	1.3B
Phi-2	2.7B
Llama2	7B, 13B, or 70B
BloombergGPT	50B
Claude2	130B
GPT-3	175B
GPT-4 "32k"	1.76T





Recette pour un bon modèle statistique



Échantillonnage des données *un échantillon = une estimation*

Train *estimation des paramètres*

- Paramètres qui optimisent la perte
- Correspond à la population d'application



Dev *estimation du biais*

- Validation Croisée ou Out Of Time
- Ajustement des hyperparamètres



Test *estimation de la variance*

- Périmètre d'application du modèle
- Estimation de la performance réelle



Cas 1 : Je veux construire un modèle pour détecter la fraude sur mes nouveaux financements. Je dispose d'un historique de financements allant du 1^{er} janvier 2000 à aujourd'hui. À ce jour, je connais les fraudes détectées par la Sécurité Financière (en moyenne 1 mois pour être détecté).

Quels échantillons de train, dev et test utiliser pour mon modèle ?



Cas 2 : Je veux construire un modèle de classification d'images en différentes pièces : factures, pièce d'identité, justificatifs... Le processus d'acquisition des données a été digitalisé l'année dernière, je dispose d'un nombre très limité de données récentes. Je dispose toutefois de documents plus anciens, envoyé par mail aux gestionnaires.

Quels échantillons de train, dev et test utiliser pour mon modèle ?



Recette pour un bon modèle statistique



Métrique(s) d'évaluation *un problème = une métrique*

Classification

- Accuracy, Precision, Recall
- AUC, Gini



Régression

- MSE, RMSE
- MAE



Computer Vision

- Intersection over Union
- Image/s



NLP

- BLEU, ROUGE, F1
- Cross-Entropy



Interprétabilité *qui a pris cette décision? C'est l'IA...*

Modèles simples *interprétation des paramètres*

EXAMPLE

- Coefficients de régression
- Seuils de classification d'un arbre




Boîtes noires = non-interprétables ?

EXAMPLE

- SHAP, LIME, Anchors...
- Activation des gradients



Les modèles de machine learning / statistiques « classiques »



Le modèle linéaire

La régression linéaire

Legendre (1805)

$$y = \beta_0 + \beta_1 X_1 + \dots + \beta_n X_n$$


“ Déterminer la droite se rapprochant au plus près des données observées. ”




Type d'apprentissage
Supervisé




Cible
Régression (linéaire) ou
Classification (logistique)



Paramètres 3 à 30
Coefficients de la régression
 $\beta_0, \dots, \beta_n$



Hyperparamètres
Nombre de variables (+ régularisation
LASSO/RIDGE/ELASTICNET)



Fonction de perte
Moindres carrés optimaux
(régression), Vraisemblance
(classification)



Processing des données
Normalisation, valeurs
manquantes et aberrantes,
découpages des variables




Interprétabilité
Coefficients de la régression et
Odds ratios, contribution des
variables




Implémentation


Entraînement ⌚




Variance faible, Biais élevé




Variance et Biais moyens



Variance élevée, Biais faible



Les arbres



CART (Classification And Regression Tree)

Breiman et al. (1984), *Classification and Regression Trees*

“

Découper une population en plusieurs groupes les plus homogènes possibles.

”




Type d'apprentissage
Supervisé



Cible
Régression ou Classification



Hyperparamètres
Profondeur maximale, échantillon minimum par feuille, seuil minimum de découpage



Fonction de perte
Variance (régression), Gini (classification)



Processing des données
Valeurs manquantes




Interprétabilité
Seuils des découpages




Implémentation


Entraînement ⌚



Variance faible, Biais élevé




Variance et Biais moyens




Variance élevée, Biais faible





Le boosting



XGBoost (eXtreme Gradient Boosting)

Chen, T. et Guestrin, C. (2016), *XGBoost : A Scalable Tree Boosting System*

“

Mutualiser la compréhension de nombreux modèles faibles.

”



Type d'apprentissage
Supervisé




Cible
Régression ou Classification



Hyperparamètres

Nombre d'arbres, learning rate, profondeur maximale, échantillon minimum par feuille, seuil minimum de découpage, régularisation, sous-échantillonnage par arbres des données et variables...



Fonction de perte

MSE (régression),
Vraisemblance (classification)



Processing des données
OneHot/OrdinalEncoder,



Interprétabilité


Modèles de substitutions,
SHAP, LIME, Feature
Importance...




Implémentation

XGBoost

Entraînement ⌚ ⌚





CNN (Convolutional Neural Networks)

Yann LeCun et al. (1989), *Backpropagation applied to Handwritten Zip Code Recognition*

“ Appliquer successivement un ensemble de filtres à une image pour en extraire des caractéristiques. ”




Type d'apprentissage
Supervisé




Cible
Classification



Paramètres 60 à 140 M
Matrices de poids, de biais,
d'activations et de filtres



Hyperparamètres
Nombre de couches, taille des couches,
régularisation, fonction d'activation,
learning rate, type/taille de pooling...



Fonction de perte
Mean Squared Error, Binary
Cross-Entropy



Processing des données
Conversion en échelle de gris,
filtre du bruit, binarisation



Interprétabilité
Identification des coordonnées
de l'image activées dans les
gradients





Image binarisée, débruitée

$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ -1 & -1 & -1 \end{bmatrix} =$$

Filtre (noyau)



Convolution



Features horizontales détectées



Implémentation
PyTorch K Keras TensorFlow
Entraînement ⌚ ⌚ ⌚ ⌚



(Camem)BERT (Bidirectional Encoder Representations from Transformers)

Google AI Language (2019), *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*

“

Faire attention au contexte d'une phrase pour comprendre le sens de chacun de ses mots.

”



Type d'apprentissage

Supervisé ou non-supervisé



Cible

Classification



Masked Language Model

S'il vous plaît, un peu **<mask>** dans la salle ! Le cours de NLP va reprendre.

2	2	2	0	1	-	0	0	3	0	3	0	2	1	3	Attention
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	-----------

Next Sentence Prediction

S'il vous plaît, un peu d'attention dans la salle !



Paramètres

345 M à 1 T
Matrices d'attentions, de poids, de biais

Hyperparamètres

Nombre de couches d'attention, régularisation



Fonction de perte

Vraisemblance des mots et des phrases prédites



Processing des données

Tokenization, racinisation, stop words



Interprétabilité

Identification des mots du textes activés dans les gradients



Implémentation



Hugging Face

Entraînement

